

Memoria Técnica del Proyecto de Deep Learning

Predicción del éxito de atracciones turísticas mediante un modelo mixto

Autor: Ricardo Moreno

1. Resumen del proyecto

El objetivo de este trabajo es crear un sistema de aprendizaje profundo que pueda adivinar si un lugar turístico tendrá mucho o poco éxito entre los usuarios. Para lograrlo, el sistema analiza dos tipos de información al mismo tiempo: por un lado, mira la fotografía principal del lugar y, por otro lado, revisa datos numéricos y de texto como sus coordenadas geográficas, categorías y etiquetas informativas.

El problema se ha planteado como una clasificación sencilla con dos respuestas posibles: cero significa que el lugar tiene un éxito o interés bajo, y uno significa que el lugar tiene un éxito o interés alto.

2. Preparación de los datos

El archivo original contenía un total de 1,569 registros con información variada. Para asegurar que el modelo aprenda de forma correcta y no haga trampas memorizando datos repetidos, se realizaron varios pasos de limpieza y organización.

2.1 Limpieza de duplicados

Se revisaron los identificadores de los lugares turísticos y se descubrió que algunos estaban repetidos. Se agruparon estos datos para dejar un único registro por cada sitio, lo que redujo el conjunto a 1,492 lugares únicos. También se comprobó que cada uno de estos lugares tuviera su archivo de imagen correspondiente en la carpeta de fotografías.

2.2 Creación de la respuesta objetivo

Para medir el éxito de cada lugar, se usaron las estadísticas de visitas, me gusta, no me gusta y marcadores guardados. Estos datos se combinaron para obtener una nota de éxito. Los lugares que quedaron por encima de la nota media se marcaron con un uno (éxito alto) y los que quedaron por debajo con un cero (éxito bajo). Es importante destacar que estas estadísticas de visitas y me gusta se borraron después de calcular la nota, para que el modelo no las viera y tuviera que adivinar el éxito usando solo la foto y la ubicación.

2.3 Organización de las características

La ubicación geográfica (longitud y latitud) y los puntos de experiencia se transformaron para que todos los números se muevan en rangos similares. Las categorías y las palabras clave se convirtieron en listas de números. Como había demasiadas palabras clave diferentes, se hizo una selección para quedarse únicamente con las más importantes y frecuentes, obteniendo un total de 70 datos numéricos listos para el modelo.

3. Diseño del modelo

El modelo diseñado es de tipo mixto porque junta dos estructuras independientes en una sola al final del camino.

Primero, una sección se encarga de procesar las imágenes. Las fotos se reducen todas a un tamaño uniforme de 128 por 128 píxeles para que la red extraiga las formas, colores y características visuales del paisaje.

Segundo, otra sección lee de forma separada los 70 datos numéricos y de ubicación geográfica del sitio turístico.

Al final, las conclusiones de la foto y las conclusiones de los datos numéricos se unen en una capa común. Esta última capa se encarga de dar la respuesta definitiva en forma de probabilidad entre cero y uno. Para evitar que el modelo memorice los ejemplos de entrenamiento de forma exacta y falle con datos nuevos, se añadieron funciones de desconexión aleatoria de neuronas y una regla de parada automática que detiene el entrenamiento si el modelo deja de mejorar con los datos de control.

4. Resultados obtenidos

Para comprobar el funcionamiento real del sistema, los datos se separaron de forma controlada en tres grupos: 954 train, 239 val y 299 test para hacer el examen técnico definitivo.

4.1 Progreso del entrenamiento

El entrenamiento duró un total de 30 ciclos de aprendizaje. Al principio, el sistema acertaba la mitad de las veces, pero fue mejorando de forma constante a medida que avanzaban los ciclos y se ajustaban los parámetros internos. Los datos registrados muestran la siguiente evolución en el error y el porcentaje de aciertos:

- Ciclo 1: Error en entrenamiento: 0.5894 | Acierto en entrenamiento: 69.50% | Error en control: 0.6685 | Acierto en control: 50.21%
- Ciclo 5: Error en entrenamiento: 0.2297 | Acierto en entrenamiento: 88.68% | Error en control: 0.9790 | Acierto en control: 49.79%
- Ciclo 15: Error en entrenamiento: 0.1324 | Acierto en entrenamiento: 94.23% | Error en control: 0.4526 | Acierto en control: 76.99%
- Ciclo 20: Error en entrenamiento: 0.1279 | Acierto en entrenamiento: 94.76% | Error en control: 0.1915 | Acierto en control: 92.05%
- Ciclo 25: Error en entrenamiento: 0.1134 | Acierto en entrenamiento: 94.86% | Error en control: 0.1571 | Acierto en control: 94.14%
- Ciclo 30: Error en entrenamiento: 0.1265 | Acierto en entrenamiento: 94.13% | Error en control: 0.1478 | Acierto en control: 95.40%

4.2 Examen final con datos ocultos

En el examen final con los 299 lugares que el modelo nunca antes había visto, el sistema consiguió una precisión global del 92.98%. De todas las pruebas realizadas, el modelo solo cometió 12 fallos al predecir un éxito alto cuando era bajo, y solo 9 fallos al predecir un éxito bajo cuando en realidad era alto.

El desglose de rendimiento para las 150 muestras de éxito bajo muestra una precisión de acierto de 0.9388 y una capacidad de detección de 0.9200. Por otro lado, las 149 muestras de éxito alto registran una precisión de acierto de 0.9211 y una capacidad de detección de 0.9396.

5. Recomendaciones futuras

Para mejorar el proyecto en el futuro, se recomienda no entrenar la sección de imágenes desde cero. En su lugar, es mejor utilizar una red que ya venga entrenada de fábrica con millones de fotos estándar y aprovechar ese conocimiento previo. También se sugiere añadir sistemas que permitan leer los textos de las descripciones breves de los lugares, que no se han usado en esta ocasión.